

徐祥烨

x57xu@uwaterloo.ca

+1-4317888226

个人主页: <https://shawnxu0407.github.io/>



教育背景

滑铁卢大学 (加拿大), 计算与应用数学, 硕士

2023.9 - 2025.12

曼尼托巴大学 (加拿大), 应用数学与统计, 本科

2019.9 - 2023.4

工作经历

Tempered AI, 数据科学 & AI 工程师

2026.2 - 至今

- 设计并构建基于 Azure Databricks 的三层级 LLM 文档抽取路由系统, 集成成本感知模型选择、数据质量预检和基于 Evidence 的幻觉检测机制, 实现 5-200+ 页保险 PDF 的大规模结构化抽取。
- 设计并实现自升级验证流水线, 在 500 份测试文档中, 减少 42% 高成本模型调用, 同时净提升 33 个字段的抽取准确率。构建 PreFlight 文档复杂度分类器, 实现三层模型路由。结合基于关键词覆盖率的数据路由机制, 自动检测并重试异常 PDF 抽取, 相比全量 o4-mini 方案降低 30% 成本, 仅增加 3% 延迟。
- 实现混合式 PDF 处理流水线, 整合 Camelot/Tabula 表格抽取、版面感知页面过滤及基于文本几何特征的伪表格识别。设计 Carrier x LOB 分层 YAML 配置体系, 并基于 Azure Functions 和 GitHub Actions 完成 CI/CD 部署, 生产环境 Evidence Accuracy 从 71% 提升至 86%, 处理成本约为每千页 0.14 美元。

皮尔公共健康 | 健康智能部门 (Region of Peel), 数据科学与数据分析 (实习)

2025.1 - 2025.4

- 将复杂公共卫生需求转化为统计建模问题, 构建 Python/SQL 数据管道, 整合多设施数据以支持预测分析。
- 使用季节性 ARIMA 与多变量回归建模人口和需求差异, 实现预测 MSE 对于基准模型下降 17%, 并生成可操作的策略洞察。
- 基于模型输出提出劳动力配置优化建议, 实现资源分配和运营效率提升。

加拿大环境与气象局 | 科技与创新部门 (Environment and Climate Change Canada), 机器学习实习生

2024.8 - 2024.12

- 将原始气象观测数据构建为图结构时空数据集, 实现空间依赖建模, 为复杂非线性天气系统提供可学习的特征表示。
- 设计并实现 GNN+Neural ODE 编码器-解码器混合模型, 捕获连续时间动态, 提高非线性天气预测的稳定性。
- 对 GNN 与 Transformer 处理器进行性能对比, 实现 Batch 推理时间减少 22.4%, 同时保持预测精度下降不显著, 新模型相对于传统数值模型推理效率显著增加。

法国巴斯德研究院 | 计算细胞部门 (Institut Pasteur), 机器学习实习生

2023.4 - 2023.8

- 对生物研究提供的细胞图像进行数据挖掘并构建预测模型, 以支持实验分析和决策, 将高维时空荧光图像数据转化为可用于定量建模的结构化特征。
- 应用 K-means 聚类以及 Gaussian Filter 进行特征工程, 将噪声像素信号转换为标准化的空间表示。
- 使用分段线性回归建模非线性速度动态, 与人工标注相比, 预测精度仅下降约 11%。

项目经历

全栈手写文字识别图像到文本模型 [GitHub]

2025.1 - 2025.4

- 将手写图像数据转化为可训练模型的结构化数据, 使用 Label-Studio 进行数据增强与标注, 并设计数据加载流程。
- 构建 CNN-Transformer 多模态模型, 在增强数据集上使用 LoRA 进行微调, 通过 Torch-Lightning 和 Weights & Biases 管理训练, 并在 AWS SageMaker 云端训练。
- 完成本地 Docker 部署与 Gradio Web UI, 最终通过 AWS Lambda 实现可扩展云端推理。

Clash Royale 游戏 AI 代理强化学习项目 [博客]

2025.4 - 2025.8

- 将游戏离线数据转化为可用于训练的特征表示, 应用视觉融合技术 (YOLOv8、cnocr、ResNet) 构建自动化数据管道。
- 基于训练数据构建决策 Transformer 策略模型, 通过 AWS SageMaker 进行云端训练与优化。
- 将视觉融合模块和策略网络部署至安卓设备, 实现实时游戏控制, 验证模型决策效果。

大语言模型敏感权重量化

2024.1 - 2024.4

- 将 Roberta 模型抽象为可量化的学习问题, 进行微调、超参数优化及自定义损失设计, 计算平均梯度敏感度。
- 提出敏感加权 K-means 权重量化方法, 结合近似 Hessian 信息及稀疏/稠密分离, 提高量化精度。
- 通过验证实现模型存储减少 90%, 预测精度仅下降约 1%, 有效压缩模型规模。

- 将历史冰球比赛数据转化为可建模能力参数，使用最大似然法构建逻辑回归模型，对球队能力进行梯度回归估计。
- 利用训练好的能力参数和赛季数据进行交叉验证，模拟不同赛季比赛表现。
- 模型预测精度达到 **78%**，提供对比赛结果的量化分析。

专业技能

资格证书：Databricks 机器学习专业证书，Databricks 数据工程专业证书

计算机语言：Python, Pytorch, PySpark, R, Tableau, Java, Matlab, MySQL

AI 框架：Docker, AWS lambda, AWS S3 bucket, AWS ECR, AWS sagemaker, weights & bias

课程：机器学习，数值算法，深度学习，数值线性代数，概率论，生物数学，统计推断

英语方面：雅思平均 8，英语口语流利

奖励荣誉

- 论文：Turing Instability of a Closed Nutrients-Phytoplankton-Zooplankton Model with time delay effect, preprint to Mathematical Bioscience (SCI 二区, under review, 2025)
- 2023 届理学院最高成绩奖
- 2022 年应用数学哲学奖 (Philosophia Mathematica Prize in Applied Mathematics, 2022)
- 暑期研究省级奖学金 (Summer Research Scholarship 2022, 2023)